Visual Analytics Milestone 2

Robin Ellerkmann
Jan-Christopher Pien
& Andreas Wegge

Aufgabe 1

Implementierung Datentyp – Tupel

- Gründe für die Nutzung von Tupeln:
  - Saubere Trennung der einzelnen Messpunkte
  - Einfacher Zugriff
  - Simple Datenstruktur
- Gründe für die ausgewählte Implementierung:
  - Entwicklung einer DataPoint-Klasse unter Nutzung des “Tuple”-Klassenbaums von Flink
  - Problematik von Tupeln in Flink
    - Keine Nullwerte erlaubt
    - Wie fehlende Werte repräsentieren?
  - Optionals innerhalb des Tupels
- Abkehr von Flink
  - Flink ist zu mächtig für konkreten Anwendungsfall
  - Geschwindigkeit leidet durch Serialisierung und Parallelisierung
  - Entscheidung für Implementierung durch reine Stream-API (Java 8)

Aufgabe 2

Funktion read_data implementieren

- mittels Java BufferedReader
- --> while loop mit parsing
- Einlesen als LinkedList und dann weitergabe als Java 8 Stream

Praktikum Visual Analytics

Aufgabe 3

Selection, Projection & Aggregation implementieren

- Interface DataSource
- Implementierung StreamDataSource kann:
  - Datei einlesen oder zufällige Daten generieren
  - Den Stream “persistent” als List speichern.
  - Die ersten N Ergebnisse einer Operation ausgeben
  - Die geforderten Operationen selection, projection und aggregation mit Komparatoren (atLeast, Same, LessThan) und Aggregatoren (avg, max, min)

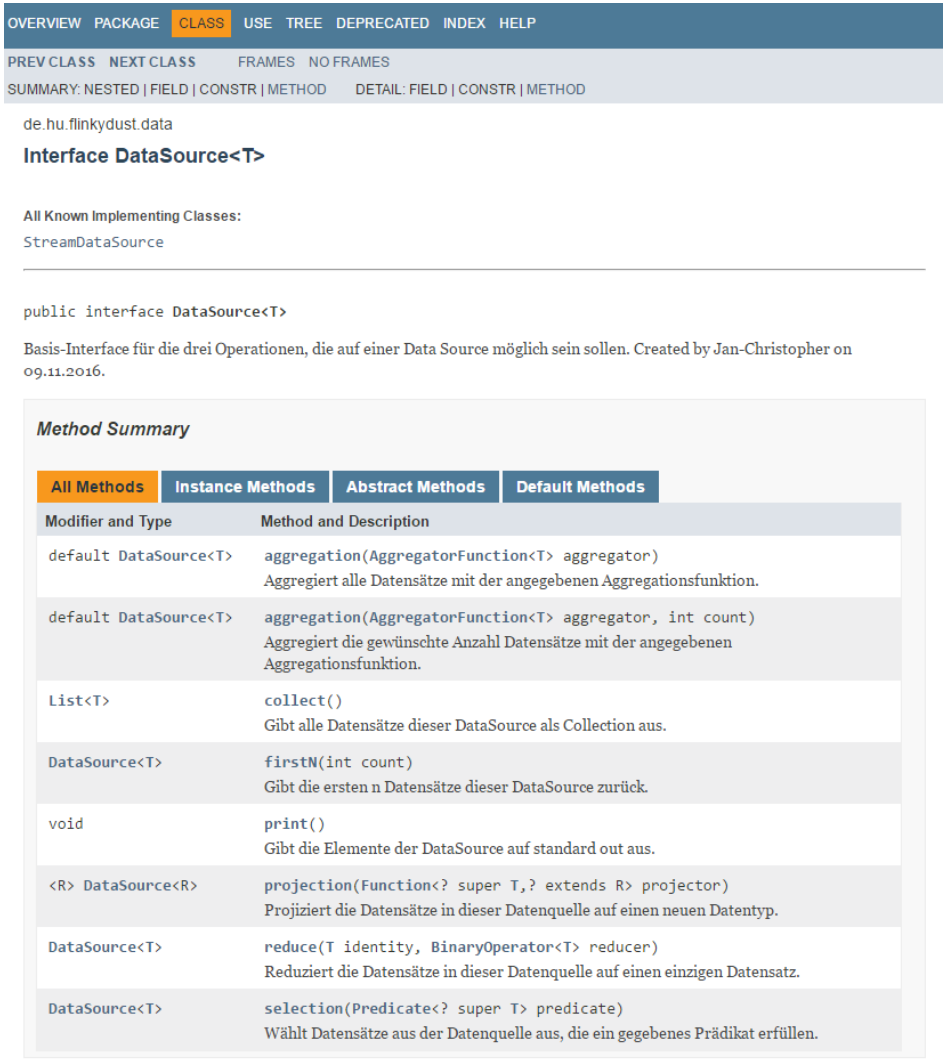

OVERVIEW PACKAGE CLASS USE TREE DEPRECATED INDEX HELP

PREV CLASS NEXT CLASS FRAMES NO FRAMES

SUMMARY: NESTED | FIELD | CONSTR | METHOD DETAIL: FIELD | CONSTR | METHOD

de.hu.flinkydust.data

Interface DataSource<T>

All Known Implementing Classes:

StreamDataSource

```
public interface DataSource<T>
```

Basis-Interface für die drei Operationen, die auf einer Data Source möglich sein sollen. Created by Jan-Christopher on 09.11.2016.

Method Summary

All Methods | Instance Methods | Abstract Methods | Default Methods

Modifier and Type	Method and Description
default DataSource<T>	aggregation(AggregatorFunction<T> aggregator) Aggregiert alle Datensätze mit der angegebenen Aggregationsfunktion.
default DataSource<T>	aggregation(AggregatorFunction<T> aggregator, int count) Aggregiert die gewünschte Anzahl Datensätze mit der angegebenen Aggregationsfunktion.
List<T>	collect() Gibt alle Datensätze dieser DataSource als Collection aus.
DataSource<T>	firstN(int count) Gibt die ersten n Datensätze dieser DataSource zurück.
void	print() Gibt die Elemente der DataSource auf standard out aus.
<R> DataSource<R>	projection(Function<? super T,? extends R> projector) Projiziert die Datensätze in dieser Datenquelle auf einen neuen Datentyp.
DataSource<T>	reduce(T identity, BinaryOperator<T> reducer) Reduziert die Datensätze in dieser Datenquelle auf einen einzigen Datensatz.
DataSource<T>	selection(Predicate<? super T> predicate) Wählt Datensätze aus der Datenquelle aus, die ein gegebenes Prädikat erfüllen.

Aufgabe 3

Spezifikation von Selection, Projection & Aggregation

- Selection (Filter)

$$R \times f \rightarrow [\{r | f(r) = true\}]$$

- Projection (Map)

$$R \times f \rightarrow [f(r_1), f(r_2), \dots, f(r_n)]$$

- Aggregation (Reduce)
  - Für einfache Aggregationen (Min, Max, Sum, etc.)

$$R \times f \times I \rightarrow f\left(r_n, f\left(r_{n-1}, f\left(\dots, f(r_1, I)\right)\right)\right)$$

  - Für kompliziertere Aggregationen (Avg) müssen mehrere Map-Reduce-Schritte hintereinandergeschaltet werden
  - Implementierung Average Aggregation:

```
Average(Stream s, Feld f):
            s.projection(tuple -> (tuple, 1))
            s.reduce((tuple1, tuple2) -> (tuple1[1][f] + tuple2[1][f], tuple1[2] + tuple2[2]))
            s.projection(tuple -> tuple[1]; tuple[1][f] = tuple[1][f] / tuple[2]))
```

Praktikum Visual Analytics

Aufgabe 4

Benchmarking durch “Profile”-Funktion

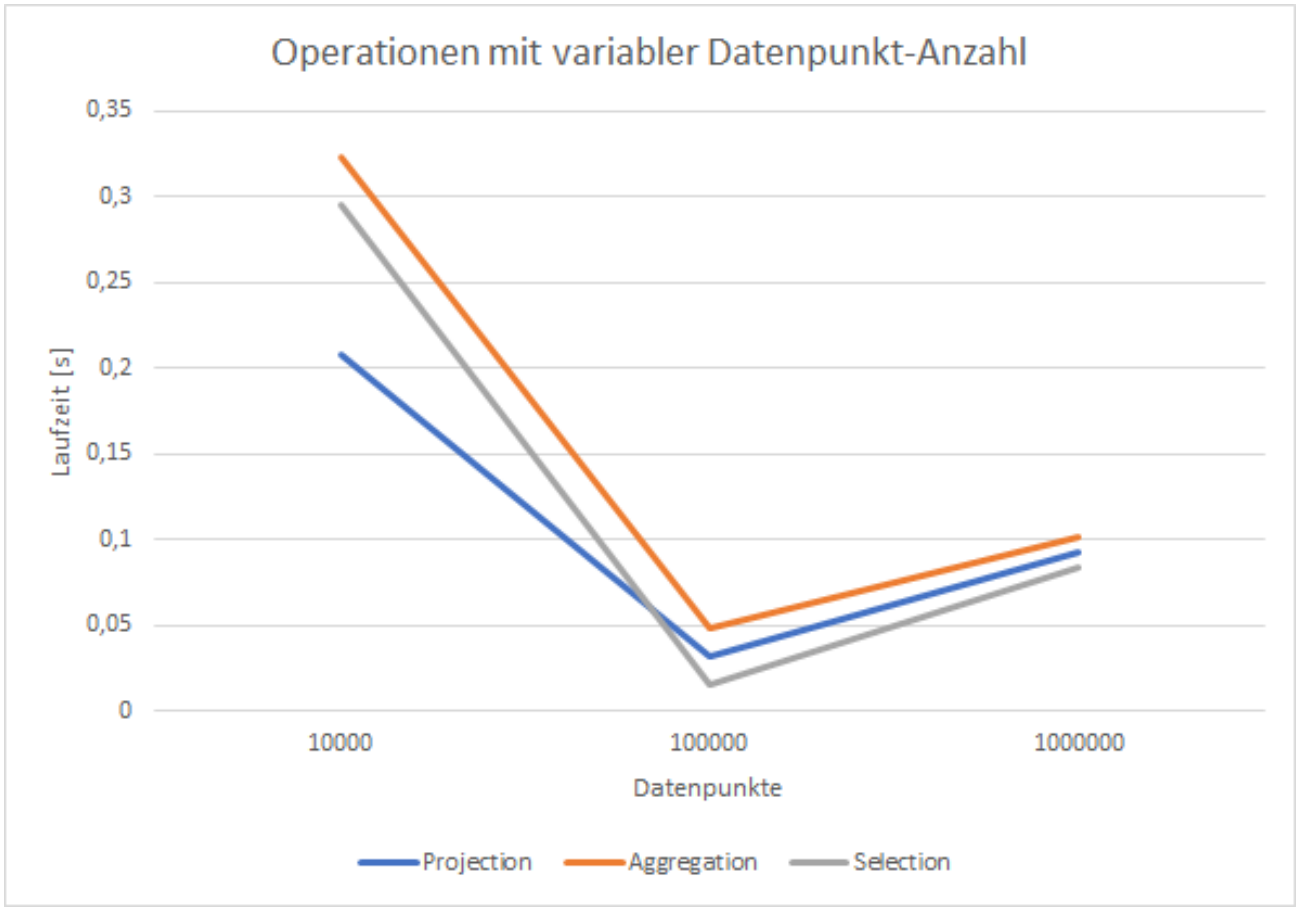

Aufgabe 5

Skalierbarkeit prüfen

- 1.000.000 Datenpunkte
- Ausreißer bei erster Messung
  - Vermutlich wegen Speicherallokation
- Testweise Implementierung mit parallelen Streams
  - Langsamer, da Overhead für das Synchronisieren von Threads nötig

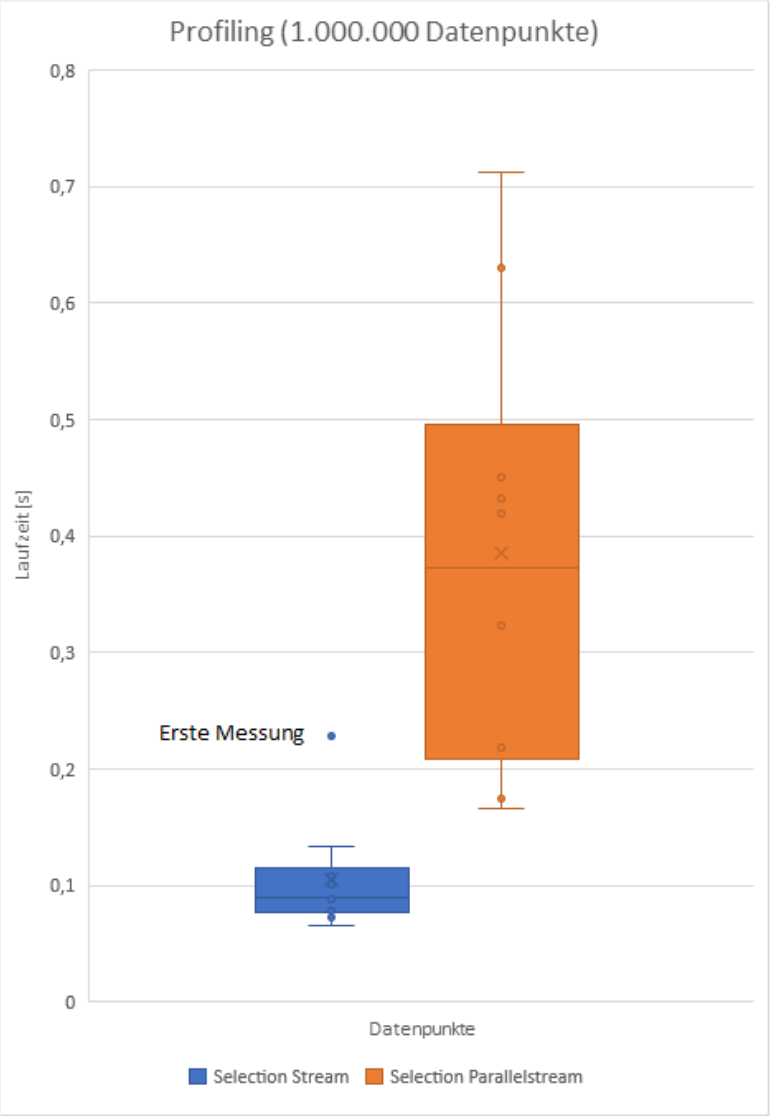

Praktikum Visual Analytics

Aufgabe 6

`Aufgabe: Zeige, dass ein Datentyp mit den Operatoren` σ `(Selektion),` π `(Projektion),` γ `(Aggregation) und` $\times$ `(Kartesisches Produkt) die folgenden Tasks unterstützt...`

1. Identifizieren:
$A = \{a_1, ..., a_n\}$ sei eine Menge von n Objekten. Identifiziere Objekte in A die eine bestimmte Bedingung erfüllen.

Definition σ: Seien $D_1, ..., D_n$ Domänen und sei $R \subseteq D_1 \times ... \times D_n$ mit $R\{A_1 : D_1, ..., A_n : D_n\}$ eine n-stellige Relation auf diesen Domänen. Sei c eine Selektionsbedingung, d. h. ein Boolscher Ausdruck aus Attributen $(A_1, ..., A_n)$, Operatoren $(=, \neq, \geq, \leq, <, >)$ und logischen Junktoren $(\wedge, \vee)$. Dann ist die Selektion wie folgt definiert:

$$\sigma_c(R) := \{\mu : (c\,[\mu] = true) \wedge (\mu \in R)\}$$

wobei μ die Tupel der Relation sind.

Die Datenstruktur enthält eine Menge A von Objekten. Die Objekte sind gleichförmige Elemente der Extension einer Relation, d.h. jedes Objekt ist ein Tupel einer bestimmten Relation R. Die Datenstruktur unterstützt weiterhin den Operator Selektion. Die Selektion σ ist äquivalent zu dem Task "Identifizieren", soweit sich die gefordeten Bedingungen als Boolscher Ausdruck beschreiben lassen. Somit lässt sich der Task "identifizieren" durch den Operator σ realisieren.

2. Vergleichen:
$A = \{a_1, ..., a_n\}$ sei eine Menge von n Objekten und $C^k = A \times_1 ... \times_k A$ eine beliebige Relation. Vergleiche Objekte $\{a_1, ..., a_k\}$ in A um geordnete Paare $a_{\pi(1)}Ca_{\pi(2)}C...Ca_{\pi(k-1)}Ca_{\pi(k)}$ zu erkennen die C^k erfüllen (π ist eine valide Permutation der Indizes).

3. Merkmale erkennen:
$A = \{a_1, ..., a_n\}$ sei eine Menge von n Objekten und F_l eine Familie von Funktionen. Erkenne alle Untermengen $\{a_1, ..., a_k\}$, die eine Funktion $F \in F_l$ zu *true* auswerten.

Aufgabenaufteilung

- Jan: Einrichten des Projekts, der Interfaces und der meisten Klassen (Komparatoren, Aggregatoren und DataSource) für Flink (1. Implementation) und dann auf Basis von Java8 Streams (2. Implementation - in Nutzung)
- Robin: Entwicklung des Profiling/Benchmarking und der zufälligen Datengenerierung, Testen und Messen, Verfeinerung der Implementierung, Präsentation und Dokumentation
- Andreas: Schreiben der Projektion und des avg-Aggregators, Verfeinerung der Implementierung, Beweisskizze (unfertig), Präsentation und Dokumentation